

Universidad de la República

Facultad de Ingeniería

Maestría en Ciencia de Datos y Aprendizaje Automático

Tarea 1

Introducción a la Ciencia de Datos

Natalia Fitipaldi
Valentina Torres

14 de mayo de 2026

Introducción

Para este trabajo se utilizará una base de datos abierta que contiene información acerca de artículos de noticias publicados en distintos medios. Los datos abarcan el período comprendido entre enero de 2016 y abril de 2020, e incluyen variables relacionadas al contenido y la identificación de cada artículo, tales como el texto completo, título, autor, URL, temática, fecha y medio de publicación.

El dataset original, All the News 2.1 - Component One, contiene aproximadamente 2,7 millones de artículos provenientes de 27 medios estadounidenses. Debido a la extensión del conjunto de datos, se trabajará con un subconjunto para poder realizar un análisis exploratorio de la producción periodística y su distribución entre diferentes medios a lo largo del tiempo.


Parte 1: Cargado y Limpieza de Datos

A. Exploración de Datos


El conjunto de datos analizado contiene 30.213 filas y 12 variables. Como primera etapa, se realizó una exploración general del dataset con el objetivo de comprender su estructura y evaluar la calidad de los datos. En este análisis no se encontraron registros duplicados, por lo que cada fila corresponde a un artículo único. Sin embargo, se detectaron datos faltantes en algunas variables: *author* presenta 11.405 valores nulos, *section* 10.232, *article* 1.176, mientras que *url* y *publication* presentan 141 valores faltantes cada una. En particular, las columnas *author* y *section* muestran una cantidad elevada de datos ausentes, lo que podría limitar futuros análisis vinculados a autores o secciones temáticas.

Posteriormente, se analizó la cantidad de artículos por medio de prensa mediante la frecuencia de la variable *publication*, y a partir de este análisis se seleccionaron los cinco medios con mayor cantidad de artículos para continuar el trabajo. Los resultados muestran que los medios con más publicaciones son *Reuters* (9.431 artículos), *The New York Times* (2.840), *CNBC* (2.623), *The Hill* (2.349) y *People* (1.528), los cuales serán utilizados para el resto del análisis.

Adicionalmente, se calculó la participación de cada uno de estos medios sobre el total de artículos del dataset, el cual está compuesto por 26 medios. En conjunto, los cinco medios seleccionados concentran el 62,2% del total de publicaciones.



B. Visualización temporal



Los gráficos muestran diferencias claras entre los medios, tanto a nivel mensual como trimestral. En general, *Reuters* es el medio con más publicaciones durante todo el período, con valores muy por encima del resto.

Es importante señalar que abril de 2020 no fue considerado en el análisis, debido a que solo se registró un artículo para ese mes. No es posible determinar si esto se debe a datos incompletos o a un error de registro, por lo que se decidió excluirlo para evitar distorsiones en el análisis temporal. Por otro lado, el medio *People* no tiene registros durante el año 2020. Sin embargo, el primer trimestre de ese año no fue excluido del análisis, ya que los demás medios sí cuentan con artículos registrados en ese período.

En el gráfico trimestral se observa que *Reuters* presenta una tendencia relativamente estable entre 2016 y 2018, con algunas variaciones, aunque hacia mediados de 2018 aparece una caída importante en la cantidad de artículos publicados. No obstante, se observa un aumento en la cantidad de artículos publicados por *Reuters* a partir de 2019, alcanzando su máximo en 2020-Q1. Este crecimiento coincide con el inicio de la pandemia de COVID-19, lo que sugiere que el contexto global pudo haber influido en un mayor volumen de publicaciones durante ese período.


Por otro lado, *CNBC* muestra un crecimiento gradual a lo largo del período. Aunque comienza con valores relativamente bajos y estables, desde 2019 se registra un aumento considerable en la cantidad de publicaciones.

The New York Times presenta un comportamiento diferente. En los primeros años muestra una tendencia descendente, pasando de niveles relativamente altos en 2016 a valores más moderados hacia 2018 y 2019.

En el caso de *The Hill* y *People*, ambos medios mantienen volúmenes menores y relativamente estables durante todo el período. *The Hill* muestra algunos picos puntuales, especialmente alrededor de 2018, mientras que *People* es el medio más constante de todos.

En el gráfico mensual se observan con mayor detalle los cambios mes a mes, destacándose *Reuters* por su volumen y la magnitud de sus variaciones, que se pierden en el gráfico trimestral por el suavizado.

En conjunto, ambos gráficos permiten identificar diferencias claras en la cobertura de cada medio a lo largo del tiempo. Mientras *Reuters* y, en menor medida, *CNBC* muestran un aumento importante en la cantidad de publicaciones hacia el final del período, los demás medios mantienen comportamientos más estables y con menores variaciones.



El análisis estacional muestra que *Reuters* es el medio con mayor cantidad de publicaciones en todos los meses del año, manteniendo niveles muy superiores al resto. Además, presenta aumentos más notorios hacia octubre y noviembre, mientras que en diciembre se observa una disminución.

En cuanto a los demás medios, *CNBC* registra un aumento gradual hasta mayo, se mantiene estable, alcanza un nuevo pico en octubre y luego disminuye. *The Hill* presenta picos en marzo y mayo, con una bajada marcada en abril entre ambos. *The New York Times* muestra variaciones leves a lo largo del año, mientras que *People* desciende después de octubre.

En general, no se observan patrones estacionales muy marcados, ya que las diferencias entre medios parecen ser más importantes que las variaciones entre meses.

Cabe señalar que el año 2020 fue excluido del análisis estacional debido a que los datos solo están disponibles hasta marzo, lo que podría sesgar la comparación mensual.

C. Limpieza de texto y conteo de palabras

Para realizar el conteo de palabras fue necesario aplicar un proceso de limpieza y normalización del texto. En primer lugar, todo el contenido se transformó a minúsculas para evitar que una misma palabra fuese contabilizada de forma diferente según el uso de mayúsculas. Esto permite unificar términos que tienen el mismo significado pero aparecen escritos de distintas maneras, como por ejemplo “Text” y “text”.

Además, se eliminaron signos de puntuación y caracteres especiales, ya que elementos como comas, puntos o símbolos podían generar registros distintos para una misma palabra y afectar el conteo final. La identificación de estos caracteres se realizó filtrando aquellos símbolos que no correspondieran a letras, números o espacios en blanco.

Posteriormente, se eliminaron los números con el fin de reducir ruido en el análisis y obtener un conteo de palabras más consistente, dado que en la mayoría de los casos no aportan información relevante sobre el contenido textual de los artículos.

Ejemplo

Antes:

Feb 2 (Reuters) - Teva Pharmaceutical Industries Ltd : * EUROPEAN MEDICINES AGENCY (EMA) ACCEPTS FREMANEZUMAB MARKETING AUTHORIZATION APPLICATION Source text for Eikon: Further company coverage:

Después:

feb reuters teva pharmaceutical industries ltd european medicines agency ema accepts fremanezumab marketing authorization application source text for eikon further company coverage

D. Elección de campos de texto

Si el objetivo es clasificar textos según el medio de prensa al que pertenecen, una opción es trabajar con el cuerpo del artículo. Este contiene mayor volumen de información y un vocabulario más amplio, lo que permite representar de mejor manera el estilo de escritura de cada medio y obtener conteos de palabras más completos.

Por otro lado, si el objetivo fuera identificar temáticas de manera general, se podría trabajar con los títulos de los artículos, ya que suelen resumir el contenido principal en pocas palabras (por ejemplo, “inflation”), facilitando una detección más rápida de los temas.

Finalmente, si se buscara un análisis más específico o detallado, se podría utilizar una combinación del título y el cuerpo del artículo, ya que esto permitiría identificar tanto temáticas generales como subtemas más concretos. Por ejemplo, el título podría indicar una temática general como “inflation”, mientras que el cuerpo del texto permitiría detectar subtemas o causas específicas relacionadas, como “higher production costs”.

E. Pistas que identifican al medio de prensa

Se analizó si en el texto aparecían pistas que permitieran identificar de forma directa al medio de prensa. En primer lugar, se buscó la presencia del nombre del propio medio dentro de los artículos. Los resultados muestran que esto ocurre con mucha frecuencia en algunos casos, especialmente en *Reuters* (8724 de 9431 artículos) y *The Hill* (2335 de 2349 artículos). En *CNBC* y *The New York Times* las menciones son menos frecuentes en términos relativos. Para el caso de *People*, el resultado debe interpretarse con cuidado, ya que “people” es una palabra de uso común en inglés y no necesariamente refiere al medio.

Además, se analizó la presencia de URLs o dominios web dentro del texto, buscando expresiones como “reuters.com” o “nytimes.com”. En general, este tipo de referencias aparece en pocos artículos, por lo que no parece ser una pista tan relevante para identificar el medio.

Por último, se identificaron expresiones repetidas y firmas de cierre. *Reuters* utiliza muy frecuentemente frases como “Reporting by” y “Editing by”, mientras que en los demás medios estas expresiones son mucho menos comunes. Este tipo de estructuras funciona como una marca muy clara del medio de origen.

En consecuencia, se considera conveniente eliminar o reducir el impacto de estas pistas durante el preprocesamiento. De lo contrario, un modelo podría identificar el medio simplemente a partir de referencias explícitas, URLs o plantillas repetidas, en lugar de aprender diferencias reales en el estilo de escritura o contenido de los artículos.

F. Restricción por sección o período temporal


Restringir el análisis a artículos de una misma sección temática o a un período temporal acotado puede ser útil para reducir el efecto del tema en una futura clasificación por medio. Si cada medio cubre temas diferentes, existe el riesgo de que el modelo aprenda a asociar ciertos temas o palabras con un medio específico, en lugar de identificar características propias de su estilo de escritura.

Trabajar con una misma sección temática permitiría comparar a los medios en un contexto más homogéneo, obligando al modelo a enfocarse más en cómo escribe cada medio y no tanto en sobre qué escribe. Del mismo modo, limitar el período temporal podría evitar diferencias asociadas a acontecimientos particulares de ciertos años.

Sin embargo, esta decisión también tiene desventajas. Restringir el análisis reduce la cantidad de datos disponibles. Además, la selección de temas y la cobertura de ciertos eventos también forman parte de la identidad de un medio, por lo que eliminar ese componente podría hacer que se pierda información relevante.

Parte 2: Conteo de Palabras y Visualizaciones

A. Palabras más frecuentes por medio




El gráfico presenta las palabras más frecuentes utilizadas por cada uno de los cinco medios de prensa. Tal como está, la interpretación es limitada debido a la presencia de *stopwords*, es decir, palabras muy frecuentes del idioma inglés que no aportan contenido informativo relevante.

Una mejora necesaria sería la eliminación de estas *stopwords* antes del análisis, lo que permitiría identificar con mayor claridad el vocabulario característico de cada medio.

A partir de esta base, la visualización podría complementarse con la incorporación de filtros adicionales. Por ejemplo, se podría segmentar por temática para comparar las palabras más frecuentes entre medios dentro de un mismo tema. También se podría agrupar los datos por períodos temporales (mensuales o anuales) para analizar variaciones en el lenguaje utilizado a lo largo del tiempo.

Limpieza de Stopwords




Al eliminar las stopwords, podemos visualizar con más claridad los términos característicos de cada medio y, en cierta forma, su enfoque editorial.

Por ejemplo, en The Hill, destacan términos claramente políticos como “trump”, “president”, “house”, “senate” y “washington”. Esto indica un enfoque en temas políticos, con énfasis en instituciones y figuras del gobierno de Estados Unidos.

Por otro lado, en CNBC, aparecen palabras asociadas a economía y mercados como “percent”, “company”, “market” y “year”, lo que refleja un perfil más financiero y económico.

En conjunto, estas diferencias en el vocabulario permiten distinguir el tipo de contenido que predomina en cada medio.

B. Medios con mayor cantidad de palabras



El gráfico muestra la cantidad total de palabras utilizadas por cada medio. Sin embargo, esta medida no permite concluir qué medio escribe artículos más extensos, ya que depende directamente de la cantidad de artículos que publica cada uno.


Por ejemplo, *The New York Times* y *Reuters* presentan valores totales de palabras similares, pero *Reuters* cuenta con 9431 artículos frente a los 2840 de *The New York Times*. Esto implica que, en promedio, los artículos del *New York Times* son más largos, mientras que *Reuters* tiende a publicar una mayor cantidad de artículos más breves.


Para una comparación más adecuada, resulta más informativo analizar el promedio de palabras por artículo en lugar del total. Esta métrica permite evaluar de forma más equilibrada la longitud media de los artículos en cada medio. Esto puede observarse en la siguiente tabla:

Table 1: Distribución de artículos y palabras por medio

Medio	Artículos	Palabras totales	Promedio palabras/artículo
The New York Times	2.840	2.595.606	914
Reuters	9.431	2.512.584	266
The Hill	2.349	1.348.007	574
CNBC	2.623	1.212.989	462
People	1.528	635.148	416

C. Matriz de menciones entre medios





Para visualizar mejor la matriz de menciones entre medios se realizó un mapa de calor, excluyendo del análisis la diagonal, ya que estos valores pueden referir tanto a automenciones, URLs, firmas, entre otros. Observando este mapa de calor, lo que más destaca son las menciones al medio *People*, pero como se mencionó anteriormente, esto debe tomarse con precaución, ya que “People” es una palabra común en inglés y no necesariamente indica una mención al medio. Entre los demás medios, se observa que *CNBC* menciona con frecuencia a *Reuters*, mientras que *The Hill* destaca por sus menciones a *Reuters* y a *The New York Times*. Las menciones cruzadas entre los otros medios son más limitadas, mostrando que la mayoría de interacciones se concentran en estos casos.

Para reducir el error al analizar las menciones al medio *People*, se podría tener en cuenta las mayúsculas para contabilizar únicamente “People” como nombre propio. No obstante, este enfoque seguiría generando ruido, ya que cualquier oración que comience con la palabra “People” también inicia con mayúscula.

Por otro lado, se realizó un grafo de menciones entre medios para visualizar con mayor claridad las relaciones identificadas anteriormente. En este gráfico, cada nodo representa un medio de prensa y las aristas indican las menciones entre ellos. Además, el grosor de las aristas varía según la cantidad de menciones registradas, mientras que la dirección de la flecha indica el sentido de la mención.

D. Preguntas propuestas

¿Es posible predecir a qué sección pertenece un artículo a partir de su contenido?

Esto podría abordarse mediante un análisis supervisado utilizando el cuerpo del artículo como variable de entrada y la sección como variable objetivo. Usando técnicas de procesamiento de lenguaje natural, se podrían entrenar modelos para clasificar automáticamente nuevos artículos en una categoría temática.

Aunque la variable *section* contiene una gran cantidad de valores faltantes, los artículos que sí cuentan con esta información podrían utilizarse para entrenar el modelo. Una vez entrenado, el modelo podría asignar una sección a los artículos que actualmente no la tienen. No obstante, la alta proporción de valores faltantes reduce la cantidad de datos disponibles para el entrenamiento, lo que podría afectar el rendimiento del modelo.

¿Existe una relación entre los autores y los medios de prensa en los que publican?

Se podría analizar la distribución de autores por medio para identificar si cada uno trabaja principalmente en una sola publicación o si existen autores compartidos entre distintos medios. Esto permitiría estudiar posibles patrones de exclusividad o colaboración entre medios.

¿Se pueden identificar noticias sensacionalistas a partir del lenguaje que utilizan?

Se podría analizar si ciertos patrones lingüísticos están asociados a un estilo más “amarillista”, como el uso de palabras emocionalmente cargadas, adjetivos extremos o estructuras de títulos llamativas. A partir de esto, se podrían construir indicadores simples, como la frecuencia de ciertos términos o el uso de signos de exclamación, para evaluar qué artículos presentan un tono más sensacionalista dentro de cada medio.

Notas:

Durante la elaboración de este trabajo se utilizó inteligencia artificial como herramienta de apoyo en distintos aspectos técnicos del proyecto, principalmente para el desarrollo y corrección de código, comprensión de errores, manejo de conflictos entre dependencias y mejora de visualizaciones. Su utilización fue especialmente útil dado que únicamente contábamos con experiencia previa en R y estamos en proceso de aprendizaje de Python.

Repositorio de GitHub

<https://github.com/valentinatorres29/IntroCD.git>